

## 応用数学

### 線形代数

#### スカラーとベクトルの違い

- ・スカラー：普通の数。ベクトルの係数になれる。
- ・ベクトル：大きさと向きを持ち、矢印で図示される。スカラーのセットで表される。

#### 行列

- ・ベクトルの変換に使う。（行列とベクトルの積）  
変換後の要素のあるひとつは、元の要素のすべてから影響を受けている。
- ・行列との積を取ることで、ベクトルの要素数の変更ができる。

#### 固有値と固有ベクトル

- ・行列とベクトルの積が、スカラーとベクトルの積で表されることがある。  
 $A \mathbf{x} = \lambda \mathbf{x}$   
この時、ベクトル（ $\mathbf{x}$ ）を固有ベクトル、スカラー（ $\lambda$ ）を固有値と呼ぶ。  
固有ベクトルで表すことで、行列とベクトルの積の計算を簡易に表せるメリットがある。
- ・固有値=単位行列×固有値で表される。  
・行列式の大きさ

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} = a d - b c$$

#### 固有値分解

- ・固有値を持つ正方行列が、固有ベクトル、固有値、固有ベクトルの逆行列の合わせ技で表される。
- ・固有値分解を行うことで、行列の特徴を表すことができる。
- ・固有値分解の手順
  - (1) 固有値を求める。  
 $A \vec{x} = \lambda \text{vec } x$   
 $\rightarrow (A - \lambda I) = 0$   
 $\rightarrow x \neq 0$  より  $|A - \lambda I| = 0$  を解く
  - (2) 固有ベクトルを求める。
  - (3) 固有ベクトルの逆行列を求める。  
3次行列の場合は掃き出し法を使う。

#### 特異値分解

- ・正方行列ではない行列について、固有値分解と似たようなことができる。  
以下が成り立つ場合、特異値分解ができる。

$$M \mathbf{v} = \sigma \mathbf{u}$$

$$M^T \mathbf{U} = \sigma \mathbf{v}$$

$$M = \mathbf{U} \mathbf{S} \mathbf{V}^{-1}$$

$\mathbf{U}$ ：行列  $\mathbf{u}$  を展開したもの。

$\mathbf{V}^{-1}$ ：行列  $\mathbf{v}$  を展開し、逆行列を取ったもの。

$\mathbf{U}$ 、 $\mathbf{V}$  の大きさは 1 に調整する。

$\mathbf{S}$ ：固有値を対角線上に並べた行列

- ・特異値ベクトル：大きさを 1 に調整されている。
- ・特異値は、 $\mathbf{M} \mathbf{M}^T$ 、 $\mathbf{M}^T \mathbf{M}$ （正方行列となる）を固有値分解して得られた特異値の 2 乗の平方根を取って求める。

## 確率・統計

### 確率

#### 頻度確率（客観確率）とベイズ確率（主観確率）

- ・頻度確率（客観確率）：実験して客観的に調べた確率
- ・ベイズ確率（主観確率）：信念の度合いを数字で表したもの

### 独立な事象の同時確率

- ・それぞれの事象が発生する確率の積で表される。
- ・  $P(X=x, Y=y) = P(X=x) P(Y=y) = P(Y=y, X=x)$

### 条件付確率

- ・ある事象  $X=x$  が与えられた下で、 $Y=y$  となる確率
- ・  $P(Y=y | X=x) = P(Y=y, X=x) / P(X=x)$

### ベイズ則

- ・  $P(\text{飴玉}) = 1/4$   
 $P(\text{笑顔} | \text{飴玉}) = 1/2$   
 $P(\text{笑顔}) = 1/3$   
 $P(\text{飴玉} | \text{笑顔}) P(\text{笑顔}) = P(\text{笑顔} | \text{飴玉}) P(\text{飴玉})$   
 $P(\text{飴玉} | \text{笑顔}) = 1/2 \times 1/4 \div 1/3 = 3/8$
- ・ベイズ則は主観確率でも客観確率でも両方使える。

### 確率変数と確率分布

- ・確率変数：事象と結びつけられた数値。事象そのものと解釈することもできる。
- ・確率分布：事象の発生する確率の分布。

### 期待値

- ・期待値  $E(f) = \sum_{k=1}^n P(X=x_k) f(X=x_k)$
- ・連続値の場合  
期待値  $E(f) = \int P(X=x_k) f(X=x_k) dx$
- ・期待値は平均値。

### 分散と共分散

- ・分散：データの散らばり具合。期待値からどれだけずれているか。  
分散  $Var(f) = E((f(X=x) - E(f))^2) = E(f^2_{X=x}) - E(f)^2$
- ・共分散：2つのデータ系列の傾向の違い。正…似た傾向、負…逆の傾向、ゼロ…関係性に乏しい。  
共分散  $Cov(f, g) = E((f(X=x) - E(f))(g(Y=y) - E(g))) = E(fg) - E(f)E(g)$
- ・データ同士の関係性を考察する場合に活用する。

### 様々な確率分布

- ・ベルヌーイ分布：コイントスのイメージ。0か1か。  
 $P(x | \mu) = \mu^x (1-\mu)^{1-x}$
- ・マルチヌーイ（カテゴリカル）分布：サイコロを転がすイメージ。  
 $P(x=1) = \lambda_1$   
 $P(x=2) = \lambda_2$   
 $P(x=3) = \lambda_3$   
 $\lambda_1 + \lambda_2 + \lambda_3 = 1$
- ・二項分布：ベルヌーイ分布の多試行版。  
 $P(x | \lambda, n) = (n! / x! (n-x)!) \mu^x (1-\mu)^{1-x}$
- ・ガウス分布：釣り鐘型の連続分布  
 $N(x; \mu, \sigma^2) = \sqrt{\frac{1}{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}\right) (x - \mu)^2$

## 情報理論

### 自己情報量

- 情報の価値（珍しさ）を表す。珍しければ価値がある。→対数を取って表す。

- $I(x) = -\log(P(x)) = \log(W(x))$

対数の底が2のとき、単位はbit。

対数の底がeのとき、単位はnat。

- $A \times B = 2^a \times 2^b = 2^{a+b}$

$$I(x) = \log_2 A \times B = a + b = \log A + \log B$$

- 情報量の定義

$$dI = \frac{dW}{W}$$

$$\int dI = \int \frac{dW}{W}$$

$$I = \int \frac{1}{W} dW = \log_e W$$

- 人間はlogの見方でものを見ている。（情報量の増え方が多いと増えたことに簡単に気づける）

### シャノンエントロピー

- 自己情報量の期待値

$$H(x) = E(I(x)) = -E(\log(P(x))) = -\sum (P(x) \log(P(x)))$$

### カルバック・ライブラー・ダイバージェンス

- 2つの事象の情報量（=確率分布）の違いを表す。

### 交差エントロピー

- KLダイバージェンスの一部を切り出したもの。
- Pを基準にQがどれだけ異なるかを表す。